


Échantillonnage et Estimation

*Estimation du nombre d'habitants d'Auvergne-Rhône-Alpes
par sondage aléatoire simple et stratifié*

Région Auvergne-Rhône-Alpes



SAE – Échantillonnage et Estimation

Science des Données – Statistique Inférentielle

Tiphaine Ducret - Oscar Makosso

Table of Contents

1	Introduction	1
2	Partie 1 – Estimation du nombre d’habitants	2
2.1	Partie 1.1 – Sondage aléatoire simple	2
2.2	Partie 1.2 – Sondage stratifié	6
3	Partie 2 – Traitement de données d’enquête.....	14
3.1	Présentation et nettoyage des données	14
3.2	Analyse et tests	16
3.3	Conclusion.....	19
4	Conclusion générale et bilan des connaissances acquises.....	19
5	Annexe – Code R complet	20

1 Introduction

L’objectif de cette SAE est d’estimer le nombre d’habitants d’une région de France métropolitaine à partir d’un processus d’échantillonnage, et d’évaluer la précision de cette estimation à l’aide d’intervalles de confiance. Il ne s’agit pas seulement d’obtenir un chiffre final, mais de comprendre comment ce chiffre est construit, quelle est sa fiabilité, et dans quelle mesure la méthode de sondage choisie influence la qualité des résultats.

La région étudiée est **Auvergne-Rhône-Alpes**, l’une des plus grandes régions de France. Elle présente une très forte diversité de communes : certaines comptent quelques dizaines d’habitants, d’autres comme Lyon dépassent 500 000 habitants. Cette hétérogénéité rend le problème statistique particulièrement intéressant et justifie la comparaison de plusieurs méthodes.

Deux méthodes de sondage sont comparées :

- Le **sondage aléatoire simple (SAS)** : chaque commune a la même probabilité d’être sélectionnée.
- Le **sondage stratifié** : les communes sont regroupées en strates homogènes selon leur taille, puis un échantillon est tiré dans chaque strate.

Une analyse de convergence des estimations en fonction de la taille d'échantillon est également proposée. Dans une seconde partie, une enquête étudiante sur la pratique sportive est analysée via des tests d'indépendance et des mesures d'intensité de liaison.

2 Partie 1 – Estimation du nombre d'habitants

2.1 Partie 1.1 – Sondage aléatoire simple

2.1.1 Préparation des données

On commence par charger le fichier Excel contenant les données de population des communes françaises. Le fichier contient plusieurs lignes d'en-tête inutiles : l'argument `skip = 6` permet de les ignorer directement à l'import. On filtre ensuite les communes d'Auvergne-Rhône-Alpes et on ne conserve que les trois colonnes utiles à l'étude : le code département, le nom de la commune et la population totale. Cette étape de préparation est indispensable — la qualité de toute analyse statistique repose d'abord sur la qualité de la base de données utilisée.

```
# Chargement du fichier Excel - skip=6 pour ignorer les lignes d'en-tête
donnees_brut <- read_excel(
  "/Users/tiphaineducret/Desktop/etudes sup/S2/sae momo/population_francaise_communes.xlsx",
  sheet = "Communes",
  skip = 6
)

# Filtrer Auvergne-Rhône-Alpes et garder 3 colonnes utiles
donnees <- data.frame(donnees_brut[
  donnees_brut$`Nom de la région` == "Auvergne-Rhône-Alpes",
  c("Code département", "Commune", "Population totale")
])
colnames(donnees) <- c("Code.département", "Commune", "Population.totale")
head(donnees)
```

	Code.département	Commune	Population.totale
## 1	01	L' Abergement-Clémenciat	821
## 2	01	L' Abergement-de-Varey	268
## 3	01	Ambérieu-en-Bugey	14662
## 4	01	Ambérieux-en-Dombes	1806
## 5	01	Ambléon	113
## 6	01	Ambronay	2946

Chaque ligne correspond à une commune. La colonne `Population.totale` est le nombre d'habitants — c'est la variable que l'on va estimer par sondage.

Le tableau obtenu contient une ligne par commune. Chaque ligne correspond à un **individu statistique** : ici, les individus ne sont pas des habitants pris un à un, mais les **communes**. La variable étudiée est le nombre total d'habitants de chaque commune.

2.1.2 Vérification et nettoyage des données

Avant toute analyse, il est indispensable de vérifier la qualité des données.

```
# Vérifier Les valeurs manquantes
sum(is.na(donnees$Population.totale))

## [1] 0

sum(is.na(donnees$Commune))

## [1] 0

# Vérifier Les doublons
sum(duplicated(donnees$Commune))

## [1] 102

# Vérifier que toutes Les populations sont positives
sum(donnees$Population.totale <= 0)

## [1] 0
```

Les 0 confirment qu'il n'y a aucune valeur manquante ni aberrante. Le 102 ne correspond pas à des erreurs : ce sont des communes homonymes dans des départements différents, que l'on conserve.

La table ne contient **aucune valeur manquante** sur les colonnes d'intérêt et **aucune valeur aberrante** (toutes les populations sont strictement positives). On note 102 communes portant le même nom : il ne s'agit pas de vrais doublons mais de **communes homonymes dans des départements différents**, phénomène courant en France (par exemple "Saint-Martin" existe dans de nombreux départements). Ces lignes sont conservées car elles correspondent bien à des communes distinctes.

2.1.3 Population U, nombre de communes N et vraie valeur T

La population U est l'ensemble des communes d'Auvergne-Rhône-Alpes. Définir précisément cette population est fondamental : un sondage n'a de sens que relativement à un ensemble de référence bien identifié.

```
# U = ensemble des communes de la région
U = donnees$Commune
head(U)

## [1] "L' Abergement-Clémenciat" "L' Abergement-de-Varey"
## [3] "Ambérieu-en-Bugey"      "Ambérieux-en-Dombes"
## [5] "Ambléon"                "Ambronay"

# Nombre total N de communes dans la région
N = length(U)
N

## [1] 4037
```

```
# Nombre exact d'habitants T (valeur de référence)
```

```
T = sum(donnees$Population.totale)
```

```
T
```

```
## [1] 8250506
```

N = 4037 est le nombre total de communes, sur lequel on va tirer l'échantillon. T = 8 250 506 est la vraie population de la région — connue ici pour vérifier nos estimations, mais inconnue dans un vrai sondage.

La région compte **4037 communes** pour un total de **8 250 506 habitants**. Cette valeur T constitue la référence de toute l'étude. Dans une situation réelle de sondage, T serait inconnue — c'est précisément le but du sondage de l'estimer. Ici, on la calcule volontairement à partir de la base complète pour pouvoir évaluer la qualité de nos estimations.

2.1.4 Échantillonnage et estimation

Le principe du sondage aléatoire simple est de tirer au hasard $n = 100$ communes parmi les 4037 de la région, sans privilégier aucune commune. Chaque commune a la même probabilité d'être choisie, d'où le nom de sondage à **probabilités égales**. La moyenne observée dans l'échantillon constitue un estimateur naturel de la moyenne μ de la population. On en déduit une estimation du total T en multipliant par N.

```
# Tirage aléatoire simple sans remise de n=100 communes
```

```
n = 100
```

```
E = sample(U, n)
```

```
head(E)
```

```
## [1] "Domarin"
```

```
"Brenthonne"
```

```
"Feissons-sur-Salins"
```

```
## [4] "Sainte-Croix"
```

```
"Saint-Christo-en-Jarez"
```

```
"Thizy-les-Bourgs"
```

```
# Table des communes sélectionnées
```

```
donnees1 = donnees[donnees$Commune %in% E, ]
```

```
head(donnees1)
```

```
##      Code.département      Commune Population.totale
```

```
## 50                01      Bourg-en-Bresse      43363
```

```
## 95                01      Chézery-Forens        464
```

```
## 136               01      Évosges              147
```

```
## 145               01      Frans                2453
```

```
## 286               01      Saint-Bernard         1528
```

```
## 296               01 Saint-Étienne-sur-Reyssouze  591
```

```
# Moyenne d'échantillon
```

```
xbar = mean(donnees1$Population.totale)
```

```
xbar
```

```
## [1] 3415.645
```

```
# IDC à 95% pour  $\mu$  via Le test de Student
```

```
idcmoy = t.test(donnees1$Population.totale)$conf.int
```

```
idcmoy
```

```
## [1] 71.17809 6760.11163
## attr(,"conf.level")
## [1] 0.95

# Estimation du total T = N * moyenne observée
T_est = N * xbar
T_est

## [1] 13788958

# IDC pour T : on multiplie les bornes de l'IDC de μ par N
idcT = idcmoy * N
idcT

## [1] 287345.9 27290570.6
## attr(,"conf.level")
## [1] 0.95

# Marge d'erreur = demi-largeur de l'IDC
marge = (idcT[2] - idcT[1]) / 2
marge

## [1] 13501612

# Différence avec la vraie valeur
T - T_est

## [1] -5538452
```

xbar est la moyenne des populations dans l'échantillon. idcmoy est l'intervalle dans lequel se trouve la vraie moyenne μ avec 95 % de confiance. On multiplie par N pour obtenir T_est, l'estimation du total. La marge indique la précision : plus elle est grande, moins l'estimation est fiable.

L'estimation obtenue est **13 788 958 habitants**, avec une marge d'erreur de **13 501 612 habitants**. La différence avec la vraie valeur de 8 250 506 est de -5 538 452 habitants. Cette marge importante montre déjà la limite du SAS sur une population aussi hétérogène qu'Auvergne-Rhône-Alpes.

2.1.5 Répétition 10 fois et résultats


Pour ne pas tirer de conclusion sur un seul tirage, on répète l'expérience 10 fois à l'aide d'une boucle for. À chaque itération, un nouvel échantillon est tiré et les résultats sont stockés dans un tableau. Cette répétition permet d'observer la **variabilité des estimations** d'un tirage à l'autre, ce qui est le cœur de la notion d'incertitude statistique. Le tableau est ensuite exporté en Excel conformément à la consigne.

##	Population_totale	Population_estimee	IDC	Marge_erreur
## 1	8250506	14160111	[2 157 976 ; 26 162 245]	12002134
## 2	8250506	7896677	[4 345 349 ; 11 448 005]	3551328
## 3	8250506	13070130	[-544 061 ; 26 684 321]	13614191
## 4	8250506	5800180	[3 840 003 ; 7 760 356]	1960177
## 5	8250506	10692406	[5 192 900 ; 16 191 912]	5499506
## 6	8250506	6783414	[3 154 534 ; 10 412 294]	3628880

## 7	8250506	8431160	[3 805 859 ; 13 056 462]	4625301
## 8	8250506	5139334	[2 611 344 ; 7 667 324]	2527990
## 9	8250506	6102344	[3 004 756 ; 9 199 933]	3097589
## 10	8250506	10341987	[4 915 745 ; 15 768 228]	5426241

Population_totale est toujours 8 250 506 — c’est la vraie valeur. Population_estimee change à chaque tirage selon l’échantillon. IDC est la fourchette estimée pour T. Marge_erreur indique la précision : plus elle est petite, meilleure est l’estimation.

Le fichier Excel a été exporté sous `resultats_sas.xlsx` avec les 4 colonnes demandées : population totale, population estimée, IDC et marge d’erreur.



Estimations du total T et marges d’erreur – SAS (10 tirages)

Les estimations sont très variables d’un tirage à l’autre et les marges d’erreur sont très importantes. La vraie valeur (ligne rouge) n’est que rarement au centre des intervalles. Cela s’explique par l’**hétérogénéité** de la région : si de grandes villes comme Lyon ou Grenoble tombent dans l’échantillon, la moyenne observée augmente fortement ; sinon, elle est très basse. Le SAS, en traitant toutes les communes de la même manière, ne tient pas compte de cette hétérogénéité et produit des estimations instables.

2.2 Partie 1.2 – Sondage stratifié


2.2.1 Visualisation de la distribution et justification des strates

Avant de créer les strates, il est utile de visualiser la distribution des tailles de communes pour comprendre pourquoi le SAS est inadapté et comment structurer le découpage.

```
par(mfrow = c(1, 2))

# Histogramme en échelle logarithmique avec seuils des strates
hist(log10(donnees$Population.totale + 1),
     breaks = 40, col = "steelblue", border = "white",
     main = "Distribution (échelle log)",
     xlab = "log10(Population totale)",
     ylab = "Nombre de communes")
abline(v = log10(c(281, 679, 1541)), col = "red", lwd = 2, lty = 2)
legend("topright", legend = "Seuils des strates",
     col = "red", lty = 2, lwd = 2, cex = 0.8)

# Zoom sur Les communes < 5000 hab
hist(donnees$Population.totale[donnees$Population.totale < 5000],
     breaks = 50, col = "steelblue", border = "white",
     main = "Zoom : communes < 5 000 hab.",
     xlab = "Population totale",
     ylab = "Nombre de communes")
```



Distribution des tailles de communes en Auvergne-Rhône-Alpes

```
par(mfrow = c(1, 1))
```

L'histogramme en échelle logarithmique confirme la forte asymétrie de la distribution : la grande majorité des communes ont moins de 1 000 habitants, mais quelques grandes villes tirent fortement la distribution vers le haut. C'est précisément cette asymétrie qui justifie le recours au sondage stratifié.

2.2.2 Création des strates (4 strates)

On divise les communes en 4 groupes homogènes selon leur taille de population, en utilisant les **quartiles** comme seuils. Ce choix est cohérent avec l'objectif de l'étude : les quartiles garantissent des strates d'effectifs à peu près égaux (~25% chacune), ce qui facilite l'allocation proportionnelle.

```
# Résumé et quantiles de Population.totale
summary(donnees$Population.totale)
```



```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1      281      679     2044     1541    176016

quantile(donnees$Population.totale)


##      0%      25%      50%      75%     100%
##      1      281      679     1541    176016

# Création de 4 strates selon les quantiles
donnees$strate = cut(donnees$Population.totale,
                     breaks = c(0, 281, 679, 1541, 176016),
                     labels = c(1, 2, 3, 4))

# Table datastrat
datastrat = donnees[ , c("Code.département", "Commune", "Population.totale", "strate")]
head(datastrat)

##      Code.département      Commune Population.totale strate
## 1      01 L' Abergement-Clémenciat           821      3
## 2      01 L' Abergement-de-Varey           268      1
## 3      01 Ambérieu-en-Bugey          14662      4
## 4      01 Ambérieux-en-Dombes          1806      4
## 5      01 Ambléon              113      1
## 6      01 Ambronay           2946      4
```

```
barplot(table(donnees$strate),
        col = c("#4e79a7", "#f28e2b", "#e15759", "#76b7b2"),
        names.arg = c("Strate 1\n(1-281 hab)", "Strate 2\n(281-679 hab)",
                      "Strate 3\n(679-1541 hab)", "Strate 4\n(>1541 hab)"),
        main = "Nombre de communes par strate",
        ylab = "Nombre de communes", border = "white")
```



Répartition des communes par strate

Les 4 strates contiennent des effectifs quasi-égaux (~1 010 communes chacune), ce qui confirme que les quartiles constituent de bons seuils pour une allocation proportionnelle équilibrée.

2.2.3 Tirage stratifié et estimation (4 strates)

L'allocation proportionnelle signifie que chaque strate contribue à l'échantillon en proportion de son poids dans la population. Le tirage est réalisé **sans remise** (srswor) dans chaque strate. Ce choix diffère du TP Belgique qui utilisait le tirage avec remise (srswr) : nous avons opté pour srswor car il est statistiquement plus efficace (variance plus faible) et évite les problèmes numériques liés aux petites strates.

```
##
##      1      2      3      4
## 1012 1007 1009 1009

##
##           1           2           3           4
## 0.2506812 0.2494427 0.2499381 0.2499381

##  1  2  3  4
## 25 25 25 25

## [1] 100
## [1] 100
## [1] 163.12
## [1] 472.28
## [1] 1011.08
## [1] 5994.8
## [1] 4298.277
## [1] 16899.21
## [1] 46700.08
## [1] 76494736
```

Nh est le nombre de communes dans chaque strate. gh est le poids de chaque strate (environ 25 % chacune). nh est le nombre de communes tirées dans chaque strate, proportionnel à sa taille. fh est le taux de sondage dans chaque strate.

On observe que les moyennes et variances augmentent fortement d'une strate à l'autre, ce qui confirme l'intérêt du découpage : les communes à l'intérieur de chaque strate sont bien plus homogènes qu'entre strates. Cependant, la variance de la strate 4 reste très élevée (~17 millions), car cette strate regroupe à la fois des villes moyennes et de très grandes agglomérations. Ce constat justifie l'amélioration proposée avec 6 strates.

```
##      1
## 1909.734
```

```
##          1          1
## 1063.149 2756.319


##          1
## 7709596

##          1          1
## 4291931 11127262

##          1
## 3417665
```

Xbarst est la moyenne stratifiée : elle combine les moyennes de chaque strate en tenant compte de leur poids dans la population. varXbarst mesure l'incertitude : plus elle est petite, plus l'IDC est étroit. Tstr est l'estimation du total T.

##	Population_totale	Population_estimee	IDC	Marge_erreur
## 1	8250506	9146701	[5 500 072 ; 12 793 331]	3646629
## 2	8250506	5950459	[3 207 751 ; 8 693 167]	2742708
## 3	8250506	12073552	[-1 437 632 ; 25 584 737]	13511184
## 4	8250506	6861654	[3 677 725 ; 10 045 583]	3183929
## 5	8250506	5112200	[4 057 524 ; 6 166 876]	1054676
## 6	8250506	13373657	[1 151 593 ; 25 595 722]	12222065
## 7	8250506	6718916	[4 711 900 ; 8 725 932]	2007016
## 8	8250506	7845409	[5 395 915 ; 10 294 903]	2449494
## 9	8250506	9041031	[4 439 434 ; 13 642 628]	4601597
## 10	8250506	8065050	[5 209 102 ; 10 920 998]	2855948



Estimations du total T et marges d'erreur – Stratifié 4 strates (10 tirages)

Les estimations varient beaucoup selon le tirage : certaines s'éloignent fortement de $T = 8\,250\,506$, avec des marges d'erreur très élevées. Cela confirme que 4 strates ne suffisent pas pour cette région.

Les résultats avec 4 strates montrent une amélioration par rapport au SAS, mais certains tirages produisent encore des estimations très éloignées de T (parfois 12 ou 13 millions). En observant les variances des strates, on constate que **la strate 4 présente une variance extrêmement élevée** : elle regroupe à la fois des villes de 1 500 habitants et des agglomérations comme Lyon (500 000 hab.) ou Grenoble (160 000 hab.), ce qui la rend beaucoup trop hétérogène. Les 4 strates ne suffisent donc pas pour cette région. On décide de passer à 6 strates en isolant les grandes agglomérations dans des strates dédiées.

2.2.4 Amélioration avec 6 strates

Pour améliorer la précision, on propose un découpage en **6 strates** avec des seuils adaptés à la structure réelle de la région. Le choix des seuils est raisonné :

- Les strates 1 à 3 reprennent les trois premiers quartiles (communes rurales et semi-rurales)
- La **strate 4** regroupe les communes de 1 541 à 10 000 habitants (villes moyennes)
- La **strate 5** regroupe les communes de 10 000 à 50 000 habitants (grandes villes)
- La **strate 6** isole les très grandes agglomérations (> 50 000 habitants : Lyon, Grenoble, Saint-Étienne...)

Ce découpage raisonné garantit que chaque strate est plus homogène que dans le cas à 4 strates, ce qui réduit la variance de l'estimateur. Les effectifs n_h ont été fixés manuellement à $c(25, 25, 25, 21, 2, 2)$ pour garantir un minimum de 2 communes par strate et un total de 100.

```
# Strates manuelles adaptées à la structure de la région
donnees$strate = cut(donnees$Population.totale,
                     breaks = c(0, 281, 679, 1541, 10000, 50000, 176016),
                     labels = c(1, 2, 3, 4, 5, 6))

datastrat = donnees[ , c("Code.département", "Commune", "Population.totale", "strate")]
data = datastrat[order(datastrat$strate), ]

Nh = table(data$strate) ; Nh

##
##      1      2      3      4      5      6
## 1012 1007 1009   896    98    15

N = sum(Nh)
gh = Nh/N

# Effectifs forcés manuellement : min 2 par strate, total = 100
n = 100
nh = c(25, 25, 25, 21, 2, 2)
sum(nh)

## [1] 100

fh = nh/Nh

# Tirage stratifié sans remise
st = strata(data, stratanames = c("strate"), size = nh, method = "srswor")
```

```

data1 = getdata(data, st)
length(data1$Commune)

## [1] 100

ech1 = data1[data1$strate==1, ] ; m1 = mean(ech1$Population.totale) ; var1 = var(ech1$Population.totale)
ech2 = data1[data1$strate==2, ] ; m2 = mean(ech2$Population.totale) ; var2 = var(ech2$Population.totale)
ech3 = data1[data1$strate==3, ] ; m3 = mean(ech3$Population.totale) ; var3 = var(ech3$Population.totale)
ech4 = data1[data1$strate==4, ] ; m4 = mean(ech4$Population.totale) ; var4 = var(ech4$Population.totale)
ech5 = data1[data1$strate==5, ] ; m5 = mean(ech5$Population.totale) ; var5 = var(ech5$Population.totale)
ech6 = data1[data1$strate==6, ] ; m6 = mean(ech6$Population.totale) ; var6 = var(ech6$Population.totale)

Xbarst = (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 +
          Nh[4]*m4 + Nh[5]*m5 + Nh[6]*m6)/N

varXbarst = ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2]) +
             ((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4]) +
             ((gh[5])^2)*(1-fh[5])*var5/(nh[5]) + ((gh[6])^2)*(1-fh[6])*var6/(nh[6])

alpha = 0.05
binf = Xbarst - qnorm(1-alpha/2)*sqrt(varXbarst)
bsup = Xbarst + qnorm(1-alpha/2)*sqrt(varXbarst)
idcmoy = c(binf, bsup)

Tstr = N*Xbarst ; Tstr

##          1
## 6838484

idcT = c(idcmoy[1]*N, idcmoy[2]*N) ; idcT


##          1          1
## 6123951 7553016

marge = (idcT[2]-idcT[1])/2 ; marge

##          1
## 714532.4

```

##	Population_totale	Population_estimee	IDC	Marge_erreur
## 1	8250506	7840115	[6 809 183 ; 8 871 046]	1030931
## 2	8250506	8148927	[6 509 669 ; 9 788 185]	1639258
## 3	8250506	8600848	[5 406 994 ; 11 794 701]	3193854
## 4	8250506	8151974	[6 892 655 ; 9 411 293]	1259319
## 5	8250506	7369130	[6 435 540 ; 8 302 721]	933590
## 6	8250506	8523247	[6 784 727 ; 10 261 767]	1738520
## 7	8250506	6923687	[5 592 535 ; 8 254 839]	1331152
## 8	8250506	7991605	[7 120 126 ; 8 863 084]	871479
## 9	8250506	6976234	[6 216 736 ; 7 735 733]	759499
## 10	8250506	9188319	[8 044 069 ; 10 332 568]	1144250



Estimations du total T et marges d'erreur – Stratifié 6 strates (10 tirages)

2.2.5 Comparaison des trois méthodes


Avec 6 strates, les estimations sont bien plus proches de $T = 8\,250\,506$ et les marges d'erreur sont nettement plus faibles. Le découpage en strates homogènes améliore clairement la précision.

##	Méthode	Marge_erreur_moyenne	Ecart_moyen_T
## 1	SAS	5593334	2497384
## 2	Stratifié 4 strates	4827525	1958226
## 3	Stratifié 6 strates	1390185	591277

Marge_erreur_moyenne : plus elle est petite, plus la méthode est précise.

Ecart_moyen_T : distance moyenne entre l'estimation et la vraie valeur T — plus elle est petite, mieux c'est. Les 6 strates donnent les meilleurs résultats sur les deux critères.

Comparaison SAS vs Stratifié 4 strates vs Stratifié 6 strates



Comparaison des trois méthodes (10 tirages chacune)

2.2.6 Conclusion comparative

La comparaison des trois approches dégage un enseignement clair. Le **SAS** produit des estimations très variables avec des marges d'erreur énormes : la méthode est conceptuellement simple mais inadaptée à une population hétérogène. Le **stratifié à 4 strates** améliore les résultats mais la strate 4 reste trop hétérogène (elle regroupe des communes de 1 500 à 176 000 habitants), ce qui génère encore des estimations aberrantes. Le **stratifié à 6 strates**, en isolant les grandes agglomérations dans des strates dédiées, produit des estimations beaucoup plus stables et plus proches de la vraie valeur $T = 8\,250\,506$ habitants.

Ce résultat illustre un principe fondamental : **plus les strates sont homogènes, plus l'estimateur est précis**. Le choix des seuils de stratification n'est pas neutre — il doit être guidé par la connaissance de la structure de la population étudiée.

3 Partie 2 – Traitement de données d'enquête

3.1 Présentation et nettoyage des données

On analyse les relations entre la pratique du sport et d'autres caractéristiques individuelles d'étudiants.

```
sport <- read_excel(
  '/Users/tiphaineducret/Desktop/etudes sup/S2/sae momo/EnqueteSportEtudiant2024.xlsx'
)
dim(sport)

## [1] 375 76
```



```

head(sport[, 1:8])

## # A tibble: 6 × 8
##   sexe      deptgeo deptgeo_Autre deptformation niveau reprise alternant bourse
##   <chr>    <chr>    <chr>          <chr>          <chr> <chr>    <chr>    <chr>
## 1 Un homme 17      <NA>          SD             BUT3  Non     Non     Non
## 2 Un homme 17      <NA>          SD             BUT3  Non     Oui     <NA>
## 3 Un homme 79      <NA>          SD             BUT3  Non     Oui     <NA>
## 4 Un homme Autre 49      SD             BUT3  Non     Oui     <NA>
## 5 Un homme Autre 35      SD             BUT3  Non     Non     Non
## 6 Un homme Autre 03      SD             BUT3  Non     Oui     <NA>

str(sport[, 1:10])

## tibble [375 × 10] (S3: tbl_df/tbl/data.frame)
## $ sexe      : chr [1:375] "Un homme" "Un homme" "Un homme" "Un homme" ...
## $ deptgeo    : chr [1:375] "17" "17" "79" "Autre" ...
## $ deptgeo_Autre: chr [1:375] NA NA NA "49" ...
## $ deptformation: chr [1:375] "SD" "SD" "SD" "SD" ...
## $ niveau     : chr [1:375] "BUT3" "BUT3" "BUT3" "BUT3" ...
## $ reprise    : chr [1:375] "Non" "Non" "Non" "Non" ...
## $ alternant   : chr [1:375] "Non" "Oui" "Oui" "Oui" ...
## $ bourse     : chr [1:375] "Non" NA NA NA ...
## $ travail    : chr [1:375] "Non" NA NA NA ...
## $ logement   : chr [1:375] "Locataire" "Locataire" "Domicilié.e chez vos (ou un de v
os ) parents" "Locataire" ...

```

La table contient **375 individus** (étudiants) et **76 variables**. Les **individus** sont les étudiants ayant répondu à l'enquête. Les **variables** sont majoritairement **qualitatives** (sexe, niveau d'études, logement, tabagisme, statut boursier...) de type chr dans R. La variable d'intérêt principale est sport (modalités : Oui / Non).

```

# Vérifier Les valeurs manquantes sur la variable d'intérêt
sum(is.na(sport$sport))

## [1] 1

# Vérifier Les doublons et valeurs manquantes sur donnees
sum(duplicated(donnees$Commune))

## [1] 102

sum(is.na(donnees$Population.totale))

## [1] 0

sum(donnees$Population.totale <= 0)

## [1] 0

# Distribution avant nettoyage
table(sport$sport)

##
## Non Oui
## 91 283

```

```
# Suppression de La ligne avec NA sur sport EN PREMIER
sport = sport[!is.na(sport$sport), ]
sum(is.na(sport$sport)) # vérification

## [1] 0

nrow(sport)

## [1] 374
```

La table sport contenait **1 valeur manquante** sur la variable sport. Cette ligne a été supprimée avant les analyses pour éviter tout biais dans les tests statistiques. La suppression est effectuée **en premier**, avant de construire les tableaux croisés et les tests, pour garantir la cohérence de toute l'analyse. La table nettoyée contient **374 étudiants**, dont 283 pratiquent un sport (75.7 %).

3.2 Analyse et tests

On choisit 5 variables qualitatives à croiser avec sport : le sexe, le niveau d'études, le statut boursier, le tabagisme et le type de logement. Ce choix permet de tester des hypothèses variées relevant du profil académique (niveau), du contexte social (bourse, logement) ou du mode de vie (fumer, sexe).

```
table(sport$sport, sport$sexe)
```

```
##
##      Un homme Une femme
## Non      48      43
## Oui     209      74
```

```
table(sport$sport, sport$niveau)
```

```
##
##      BUT1 BUT2 BUT3 Licence Pro
## Non    46  26  15         3
## Oui   107  81  66         29
```

```
table(sport$sport, sport$bourse)
```


```
##
##      Non Oui
## Non   36  30
## Oui  109  58
```

```
table(sport$sport, sport$fumer)
```

```
##
##      Non Oui
## Non   73  18
## Oui  237  46
```

```
table(sport$sport, sport$logement)
```

```
##
##      Autre Domicilié.e chez vos (ou un de vos ) parents Locataire
## Non      1          33          57
## Oui      7          80         196
```



Pratique du sport selon les variables qualitatives choisies

Ces graphiques permettent une lecture descriptive : les hommes semblent pratiquer davantage le sport que les femmes, et les différences pour les autres variables sont moins marquées. Les tests du khi-deux permettront de confirmer ou d'infirmer ces observations visuelles.

```
# Vérification des effectifs avant Les tests
# Pour logement : modalité "Autre" a des effectifs trop faibles (1 Non, 7 Oui)
# → effectifs théoriques < 5, ce qui viole les conditions d'application du test
# On retire cette modalité pour ce test uniquement
table(sport$sport, sport$logement)

##
##      Autre Domicilié.e chez vos (ou un de vos ) parents Locataire
##   Non      1                                33             57
##   Oui      7                                80            196

sport_log = sport[sport$logement != "Autre", ]

# Tests du khi-deux d'indépendance (H0 : indépendance entre sport et la variable)
chi_sexe    = chisq.test(table(sport$sport, sport$sexe))
chi_niveau  = chisq.test(table(sport$sport, sport$niveau))
chi_bourse  = chisq.test(table(sport$sport, sport$bourse))
chi_fumer   = chisq.test(table(sport$sport, sport$fumer))
```

```

chi_logement = chisq.test(table(sport_log$sport, sport_log$logement))

# Tableau récapitulatif
resultats_chi = data.frame(
  Variable = c("sexe", "niveau", "bourse", "fumer", "logement"),
  p_valeur = round(c(chi_sexe$p.value, chi_niveau$p.value, chi_bourse$p.value,
                     chi_fumer$p.value, chi_logement$p.value), 4),
  Significatif = c(chi_sexe$p.value < 0.05, chi_niveau$p.value < 0.05,
                  chi_bourse$p.value < 0.05, chi_fumer$p.value < 0.05,
                  chi_logement$p.value < 0.05)
)
print(resultats_chi)

## Variable p_valeur Significatif
## 1 sexe 0.0003 TRUE
## 2 niveau 0.0431 TRUE
## 3 bourse 0.1702 FALSE
## 4 fumer 0.5373 FALSE
## 5 logement 0.2156 FALSE

```

Pour le test sur logement, la modalité “Autre” ne contient que 8 observations (1 Non + 7 Oui), ce qui génère des effectifs théoriques inférieurs à 5 — condition nécessaire à la validité du test du khi-deux. Cette modalité a donc été retirée pour ce test uniquement, en conservant les modalités “Locataire” et “Domicilié chez les parents”.

Deux variables ont une relation **significative** avec la pratique du sport au seuil $\alpha = 5\%$: le **sexe** ($p = 0,0003$) et le **niveau d'études** ($p = 0,043$). Les variables bourse, fumer et logement ne montrent pas de relation significative.

```

# V de Cramer pour les tests significatifs uniquement
tab_sexe = table(sport$sport, sport$sexe)
n = sum(tab_sexe) ; p = nrow(tab_sexe) ; q = ncol(tab_sexe) ; m = min(p-1, q-1)
V_sexe = sqrt(chi_sexe$statistic/(n*m))
V_sexe

## X-squared
## 0.1885908


tab_niveau = table(sport$sport, sport$niveau)
n = sum(tab_niveau) ; p = nrow(tab_niveau) ; q = ncol(tab_niveau) ; m = min(p-1, q-1)
V_niveau = sqrt(chi_niveau$statistic/(n*m))
V_niveau

## X-squared
## 0.1477691

# Tableau final
resultats_final = data.frame(
  Variable = c("sexe", "niveau"),
  p_valeur = round(c(chi_sexe$p.value, chi_niveau$p.value), 4),
  V_Cramer = round(c(V_sexe, V_niveau), 4)
)
print(resultats_final)

```

##	Variable	p_valeur	V_Cramer
## 1	sexe	0.0003	0.1886
## 2	niveau	0.0431	0.1478



Intensité des liaisons significatives (V de Cramer)

3.3 Conclusion

Deux variables sont significativement liées à la pratique du sport : le **sexe** ($p = 3^{-4}$, $V = 0.189$) et le **niveau d'études** ($p = 0.0431$, $V = 0.148$). Il faut distinguer deux idées importantes : d'un côté, le test du khi-deux indique qu'il existe une dépendance statistique ; de l'autre, le V de Cramer montre que cette dépendance est **faible** ($V < 0,2$). La liaison la plus forte est celle avec le sexe. En regardant le tableau croisé, les hommes pratiquent le sport à environ 81 % contre 63 % pour les femmes.

4 Conclusion générale et bilan des connaissances acquises

Ce travail nous a permis de mobiliser et d'approfondir plusieurs notions fondamentales de la statistique inférentielle.

Sur l'échantillonnage et l'estimation : nous avons appris à construire un estimateur du total d'une population à partir d'un échantillon, et à quantifier l'incertitude associée via un intervalle de confiance. Le plan de sondage est un choix méthodologique décisif : le SAS est simple mais inadapté aux populations hétérogènes. Le sondage stratifié, en exploitant la structure connue de la population, produit des estimations plus précises. Le choix des seuils de stratification n'est pas neutre — il doit être guidé par la connaissance de la structure de la population, comme nous l'avons montré en passant de 4 à 6 strates avec des seuils raisonnés.

Sur la notion d'intervalle de confiance : un IDC à 95 % ne garantit pas que la vraie valeur est dedans pour un tirage donné, mais que sur un grand nombre de tirages, 95 % des intervalles construits la contiendraient. Les simulations répétées 10 fois ont permis de visualiser concrètement cette variabilité.

Sur le choix du tirage : nous avons opté pour le tirage sans remise (srswor) plutôt qu’avec remise (srswr) utilisé dans le TP Belgique. Ce choix est statistiquement justifié : le srswor produit une variance plus faible et évite les problèmes numériques sur les petites strates.

Sur l’analyse d’enquête : les tests du khi-deux permettent d’identifier des relations significatives entre variables qualitatives. Le V de Cramer quantifie l’intensité de ces liaisons. Une distinction importante : une relation peut être statistiquement significative sans être fortement intense. La condition d’application du test (effectifs théoriques ≥ 5) doit être vérifiée avant tout test.

Bilan général : cette SAE montre que la qualité d’une analyse statistique ne dépend pas seulement des formules utilisées, mais aussi de la manière dont les données ont été collectées, structurées et interprétées. Ces méthodes sont au coeur de nombreuses études réelles : sondages électoraux, enquêtes de santé, études de marché, recensements de population.

5 Annexe – Code R complet

```
# SAE - Echantillonnage et Estimation
# Région : Auvergne-Rhône-Alpes

library(readxl)
library(sampling)
library(writexl)

# =====
# PARTIE 1.1 - Sondage aléatoire simple (SAS)
# =====

# Chargement du fichier Excel - skip=6 pour ignorer les lignes d'en-tête
donnees_brut <- read_excel(
  "/Users/tiphaineducret/Desktop/etudes sup/S2/sae momo/population_francaise_communes.xlsx",
  sheet = "Communes", skip = 6
)

# Filtrer Auvergne-Rhône-Alpes et garder 3 colonnes utiles
donnees <- data.frame(donnees_brut[
  donnees_brut$`Nom de la région` == "Auvergne-Rhône-Alpes",
  c("Code département", "Commune", "Population totale")
])
colnames(donnees) <- c("Code.département", "Commune", "Population.totale")
head(donnees)

# Vérification et nettoyage des données
sum(is.na(donnees$Population.totale)) # valeurs manquantes
sum(is.na(donnees$Commune))
sum(duplicated(donnees$Commune))      # 102 homonymes (communes de même nom dans des dept
s différents)
sum(donnees$Population.totale <= 0)    # valeurs aberrantes

# U = ensemble des communes (individus statistiques)
U = donnees$Commune
```

```

# Nombre total N de communes dans La région
N = length(U)
N
# Nombre exact d'habitants T (valeur de référence)
T = sum(donnees$Population.totale)
T

# Tirage aléatoire simple sans remise de n=100 communes
n = 100
E = sample(U, n)
# Table des communes sélectionnées
donnees1 = donnees[donnees$Commune %in% E, ]
head(donnees1)
# Moyenne d'échantillon
xbar = mean(donnees1$Population.totale)
xbar
# IDC à 95% pour  $\mu$  via Le test de Student
idcmoy = t.test(donnees1$Population.totale)$conf.int
idcmoy
# Estimation du total  $T = N * \text{moyenne observée}$ 
T_est = N * xbar
T_est
# IDC pour T : on multiplie les bornes de l'IDC de  $\mu$  par N
idcT = idcmoy * N
idcT
# Marge d'erreur = demi-largeur de l'IDC
marge = (idcT[2] - idcT[1]) / 2
marge
# Différence avec la vraie valeur
T - T_est

# Répétition 10 fois pour observer la variabilité des estimations
resultats <- data.frame(
  Population_totale = numeric(10),
  Population_estimee = numeric(10),
  IDC_inf = numeric(10),
  IDC_sup = numeric(10),
  Marge_erreur = numeric(10)
)
for (i in 1:10) {
  # Tirage aléatoire simple
  E_i = sample(U, n)
  # Table des communes sélectionnées
  donnees1_i = donnees[donnees$Commune %in% E_i, ]
  # Moyenne et IDC de  $\mu$ 
  xbar_i = mean(donnees1_i$Population.totale)
  idcmoy_i = t.test(donnees1_i$Population.totale)$conf.int
  # Estimation de T, IDC et marge
  T_est_i = N * xbar_i
  idcT_i = idcmoy_i * N
  marge_i = (idcT_i[2] - idcT_i[1]) / 2
  # Sauvegarder les résultats
  resultats[i, ] = c(T, round(T_est_i), round(idcT_i[1]), round(idcT_i[2]), round(marge_i))
}

# Export Excel avec les 4 colonnes demandées
sas_excel = data.frame(
  Population_totale = resultats$Population_totale,
  Population_estimee = resultats$Population_estimee,

```

```

IDC = paste0("[", format(resultats$IDC_inf, big.mark=" "),
              "; ", format(resultats$IDC_sup, big.mark=" "), "]"),
Marge_erreur = resultats$Marge_erreur
)
write_xlsx(sas_excel,
           "/Users/tiphaineducret/Desktop/etudes sup/S2/sae momo/resultats_sas.xlsx")

# Graphique : T estimé vs T vrai avec barres de marge d'erreur (axe en millions)
pop_est_M = resultats$Population_estimee / 1e6
marges_M = resultats$Marge_erreur / 1e6
plot(1:10, pop_est_M,
     ylim = c(min(pop_est_M - marges_M)*0.95, max(pop_est_M + marges_M)*1.05),
     pch = 19, col = "steelblue", cex = 1.2,
     xlab = "Tirage n°", ylab = "Population estimée (millions d'habitants)",
     main = "Estimations de T - Auvergne-Rhône-Alpes (SAS)", yaxt = "n")
axis(2, at = seq(0, 30, by = 2), labels = paste0(seq(0, 30, by = 2), "M"))
abline(h = T/1e6, col = "red", lwd = 2, lty = 2) # vraie valeur en rouge
arrows(1:10, pop_est_M - marges_M, 1:10, pop_est_M + marges_M,
       angle = 90, code = 3, length = 0.08, col = "steelblue")
legend("topright", legend = c("T estimé", "T vrai"),
      col = c("steelblue", "red"), lty = c(NA, 2), pch = c(19, NA))

# =====
# PARTIE 1.2 - Sondage stratifié (4 strates)
# =====

# Résumé et quantiles pour définir Les seuils des strates
summary(donnees$Population.totale)
quantile(donnees$Population.totale)

# Création de 4 strates selon Les quantiles
donnees$strate = cut(donnees$Population.totale,
                    breaks = c(0, 281, 679, 1541, 176016),
                    labels = c(1, 2, 3, 4))

# Table datastrat avec La colonne strate
datastrat = donnees[, c("Code.département", "Commune", "Population.totale", "strate")]
head(datastrat)

# Trier par strate pour Le tirage
data = datastrat[order(datastrat$strate), ]

# Effectifs des strates
Nh = table(data$strate) ; Nh
N = sum(Nh)
# Poids des strates
gh = Nh/N ; gh
# Effectifs proportionnels : nh = n * Nh/N
n = 100
nh = round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N))
nh ; sum(nh)
# Taux de sondage dans Les strates
fh = nh/Nh

# Tirage stratifié sans remise (srswor plus efficace que srswr)
st = strata(data, stratanames = c("strate"), size = nh, method = "srswor")
data1 = getdata(data, st)
length(data1$Commune)

# Définir Les 4 sous-échantillons et calculer moyennes et variances
ech1 = data1[data1$strate==1, ] ; m1 = mean(ech1$Population.totale) ; var1 = var(ech1$Popu

```



```

lation.totale)
ech2 = data1[data1$strate==2, ] ; m2 = mean(ech2$Population.totale) ; var2 = var(ech2$Popu
lation.totale)
ech3 = data1[data1$strate==3, ] ; m3 = mean(ech3$Population.totale) ; var3 = var(ech3$Popu
lation.totale)
ech4 = data1[data1$strate==4, ] ; m4 = mean(ech4$Population.totale) ; var4 = var(ech4$Popu
lation.totale)
m1; m2; m3; m4
var1; var2; var3; var4

# Moyenne stratifiée pondérée par les tailles de strate
Xbarst = (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4)/N
# Variance de Xbarst (formule du cours avec taux de sondage fh)
varXbarst = ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2]) +
              ((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4])
# IDC asymptotique pour  $\mu$  à 95%
alpha = 0.05
binf = Xbarst - qnorm(1-alpha/2)*sqrt(varXbarst)
bsup = Xbarst + qnorm(1-alpha/2)*sqrt(varXbarst)
idcmoy = c(binf, bsup)
Xbarst ; idcmoy
# Estimation du total T
Tstr = N*Xbarst ; Tstr
idcT = c(idcmoy[1]*N, idcmoy[2]*N) ; idcT
marge = (idcT[2]-idcT[1])/2 ; marge

# Répétition 10 fois
resultats_strat = data.frame(
  Population_totale = numeric(10),
  Population_estimee = numeric(10),
  IDC_inf = numeric(10),
  IDC_sup = numeric(10),
  Marge_erreur = numeric(10)
)
for (i in 1:10) {
  # Tirage stratifié sans remise
  st_i = strata(data, stratanames = c("strate"), size = nh, method = "srswor")
  data1_i = getdata(data, st_i)
  # Sous-échantillons, moyennes et variances par strate
  ech1_i = data1_i[data1_i$strate==1, ] ; m1_i = mean(ech1_i$Population.totale) ; var1_i =
var(ech1_i$Population.totale)
  ech2_i = data1_i[data1_i$strate==2, ] ; m2_i = mean(ech2_i$Population.totale) ; var2_i =
var(ech2_i$Population.totale)
  ech3_i = data1_i[data1_i$strate==3, ] ; m3_i = mean(ech3_i$Population.totale) ; var3_i =
var(ech3_i$Population.totale)
  ech4_i = data1_i[data1_i$strate==4, ] ; m4_i = mean(ech4_i$Population.totale) ; var4_i =
var(ech4_i$Population.totale)
  # Moyenne stratifiée et sa variance
  Xbarst_i = (Nh[1]*m1_i + Nh[2]*m2_i + Nh[3]*m3_i + Nh[4]*m4_i)/N
  varXbarst_i = ((gh[1])^2)*(1-fh[1])*var1_i/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2_i/(nh[2])
) +
              ((gh[3])^2)*(1-fh[3])*var3_i/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4_i/(nh[4])
)
  # IDC de  $\mu$  puis de T
  binf_i = Xbarst_i - qnorm(1-alpha/2)*sqrt(varXbarst_i)
  bsup_i = Xbarst_i + qnorm(1-alpha/2)*sqrt(varXbarst_i)
  idcmoy_i = c(binf_i, bsup_i)
  Tstr_i = N*Xbarst_i ; idcT_i = idcmoy_i*N
  marge_i = (idcT_i[2]-idcT_i[1])/2
  # Sauvegarder les résultats

```

```

    resultats_strat[i, ] = c(T, round(Tstr_i), round(idcT_i[1]), round(idcT_i[2]), round(marge_i))
  }

# Export Excel
write_xlsx(data.frame(
  Population_totale = resultats_strat$Population_totale,
  Population_estimee = resultats_strat$Population_estimee,
  IDC = paste0("[", format(resultats_strat$IDC_inf, big.mark=" "), " ; ",
    format(resultats_strat$IDC_sup, big.mark=" "), " ]"),
  Marge_erreur = resultats_strat$Marge_erreur),
  "/Users/tiphaineducret/Desktop/etudes sup/S2/sae momo/resultats_strat4.xlsx")

# =====
# PARTIE 1.2 - Amélioration avec 6 strates (Lyon/Grenoble isolés)
# =====

# Quantiles pour justifier le découpage
quantile(donnees$Population.totale, probs = seq(0, 1, by = 0.125))

# Strates manuelles adaptées à la structure de la région :
# strates 1-3 : quartiles (rural), strate 4 : villes moyennes,
# strate 5 : grandes villes, strate 6 : très grandes agglomérations
donnees$strate = cut(donnees$Population.totale,
  breaks = c(0, 281, 679, 1541, 10000, 50000, 176016),
  labels = c(1, 2, 3, 4, 5, 6))
datastrat = donnees[ , c("Code.département", "Commune", "Population.totale", "strate")]
data = datastrat[order(datastrat$strate), ]

# Effectifs et poids des 6 strates
Nh = table(data$strate) ; Nh
N = sum(Nh)
gh = Nh/N

# Effectifs forcés manuellement : min 2 par strate, total = 100
# (l'allocation proportionnelle donnait nh=0 pour strate 6)
n = 100
nh = c(25, 25, 25, 21, 2, 2)
sum(nh)
# Taux de sondage dans les strates
fh = nh/Nh

# Tirage stratifié sans remise
st = strata(data, stratanames = c("strate"), size = nh, method = "srswor")
data1 = getdata(data, st)
length(data1$Commune)

# Sous-échantillons, moyennes et variances
ech1 = data1[data1$strate==1, ] ; m1 = mean(ech1$Population.totale) ; var1 = var(ech1$Population.totale)
ech2 = data1[data1$strate==2, ] ; m2 = mean(ech2$Population.totale) ; var2 = var(ech2$Population.totale)
ech3 = data1[data1$strate==3, ] ; m3 = mean(ech3$Population.totale) ; var3 = var(ech3$Population.totale)
ech4 = data1[data1$strate==4, ] ; m4 = mean(ech4$Population.totale) ; var4 = var(ech4$Population.totale)
ech5 = data1[data1$strate==5, ] ; m5 = mean(ech5$Population.totale) ; var5 = var(ech5$Population.totale)
ech6 = data1[data1$strate==6, ] ; m6 = mean(ech6$Population.totale) ; var6 = var(ech6$Population.totale)

```

```

# Moyenne stratifiée et sa variance
Xbarst = (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 +
          Nh[4]*m4 + Nh[5]*m5 + Nh[6]*m6)/N
varXbarst = ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2]) +
             ((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4]) +
             ((gh[5])^2)*(1-fh[5])*var5/(nh[5]) + ((gh[6])^2)*(1-fh[6])*var6/(nh[6])
# IDC pour  $\mu$  à 95%
alpha = 0.05
binf = Xbarst - qnorm(1-alpha/2)*sqrt(varXbarst)
bsup = Xbarst + qnorm(1-alpha/2)*sqrt(varXbarst)
idcmoy = c(binf, bsup)
# Estimation du total T
Tstr = N*Xbarst ; Tstr
idcT = c(idcmoy[1]*N, idcmoy[2]*N) ; idcT
marge = (idcT[2]-idcT[1])/2 ; marge

# Répétition 10 fois
resultats_6strat = data.frame(
  Population_totale = numeric(10),
  Population_estimee = numeric(10),
  IDC_inf = numeric(10),
  IDC_sup = numeric(10),
  Marge_erreur = numeric(10)
)
for (i in 1:10) {
  st_i = strata(data, stratanames = c("strate"), size = nh, method = "srswor")
  data1_i = getdata(data, st_i)
  ech1_i = data1_i[data1_i$strate==1, ] ; m1_i = mean(ech1_i$Population_totale) ; var1_i =
var(ech1_i$Population_totale)
  ech2_i = data1_i[data1_i$strate==2, ] ; m2_i = mean(ech2_i$Population_totale) ; var2_i =
var(ech2_i$Population_totale)
  ech3_i = data1_i[data1_i$strate==3, ] ; m3_i = mean(ech3_i$Population_totale) ; var3_i =
var(ech3_i$Population_totale)
  ech4_i = data1_i[data1_i$strate==4, ] ; m4_i = mean(ech4_i$Population_totale) ; var4_i =
var(ech4_i$Population_totale)
  ech5_i = data1_i[data1_i$strate==5, ] ; m5_i = mean(ech5_i$Population_totale) ; var5_i =
var(ech5_i$Population_totale)
  ech6_i = data1_i[data1_i$strate==6, ] ; m6_i = mean(ech6_i$Population_totale) ; var6_i =
var(ech6_i$Population_totale)
  Xbarst_i = (Nh[1]*m1_i + Nh[2]*m2_i + Nh[3]*m3_i +
             Nh[4]*m4_i + Nh[5]*m5_i + Nh[6]*m6_i)/N
  varXbarst_i = ((gh[1])^2)*(1-fh[1])*var1_i/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2_i/(nh[2])
+
             ((gh[3])^2)*(1-fh[3])*var3_i/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4_i/(nh[4]) +
             ((gh[5])^2)*(1-fh[5])*var5_i/(nh[5]) + ((gh[6])^2)*(1-fh[6])*var6_i/(nh[6])
  binf_i = Xbarst_i - qnorm(1-alpha/2)*sqrt(varXbarst_i)
  bsup_i = Xbarst_i + qnorm(1-alpha/2)*sqrt(varXbarst_i)
  idcmoy_i = c(binf_i, bsup_i)
  Tstr_i = N*Xbarst_i ; idcT_i = idcmoy_i*N
  marge_i = (idcT_i[2]-idcT_i[1])/2
  resultats_6strat[i, ] = c(T, round(Tstr_i), round(idcT_i[1]), round(idcT_i[2]), round(ma
rge_i))
}

# Export Excel
write_xlsx(data.frame(
  Population_totale = resultats_6strat$Population_totale,
  Population_estimee = resultats_6strat$Population_estimee,
  IDC = paste0("[", format(resultats_6strat$IDC_inf, big.mark=" "), " ; ",

```

```

        format(resultats_6strat$IDC_sup, big.mark=" "), "]),
Marge_erreur = resultats_6strat$Marge_erreur),
"/Users/tiphaineducret/Desktop/etudes sup/S2/sae momo/resultats_strat6.xlsx")

# =====
# PARTIE 2 - Traitement de données d'enquête
# =====

# Importer La table sport
sport <- read_excel(
  '/Users/tiphaineducret/Desktop/etudes sup/S2/sae momo/EnqueteSportEtudiant2024.xlsx'
)
dim(sport)
head(sport[, 1:8])
str(sport[, 1:10])

# Vérification et nettoyage
sum(is.na(sport$sport))          # 1 NA détecté
sum(duplicated(donnees$Commune)) # 102 homonymes (normal)
sum(is.na(donnees$Population.totale))
sum(donnees$Population.totale <= 0)

# Suppression du NA sur sport EN PREMIER avant toute analyse
sport = sport[!is.na(sport$sport), ]
sum(is.na(sport$sport)) # vérification : doit être 0
nrow(sport)
table(sport$sport)

# Tableaux croisés de sport avec Les 5 variables choisies
table(sport$sport, sport$sexe)
table(sport$sport, sport$niveau)
table(sport$sport, sport$bourse)
table(sport$sport, sport$fumer)
table(sport$sport, sport$logement)

# Pour Logement : modalité "Autre" retirée (effectifs théoriques < 5)
sport_log = sport[sport$logement != "Autre", ]
table(sport_log$sport, sport_log$logement) # vérification

# Tests du khi-deux d'indépendance (H0 : indépendance entre sport et La variable)
chi_sexe      = chisq.test(table(sport$sport, sport$sexe))
chi_niveau    = chisq.test(table(sport$sport, sport$niveau))
chi_bourse    = chisq.test(table(sport$sport, sport$bourse))
chi_fumer     = chisq.test(table(sport$sport, sport$fumer))
chi_logement  = chisq.test(table(sport_log$sport, sport_log$logement))

# Tableau récapitulatif des p-valeurs
resultats_chi = data.frame(
  Variable      = c("sexe", "niveau", "bourse", "fumer", "logement"),
  p_valeur      = round(c(chi_sexe$p.value, chi_niveau$p.value, chi_bourse$p.value,
                           chi_fumer$p.value, chi_logement$p.value), 4),
  Significatif  = c(chi_sexe$p.value < 0.05, chi_niveau$p.value < 0.05,
                    chi_bourse$p.value < 0.05, chi_fumer$p.value < 0.05,
                    chi_logement$p.value < 0.05)
)
print(resultats_chi)

# V de Cramer pour Les tests significatifs uniquement (sexe et niveau)
tab_sexe = table(sport$sport, sport$sexe)

```

```

n = sum(tab_sexe) ; p = nrow(tab_sexe) ; q = ncol(tab_sexe) ; m = min(p-1, q-1)
V_sexe = sqrt(chi_sexe$statistic/(n*m))
V_sexe

tab_niveau = table(sport$sport, sport$niveau)
n = sum(tab_niveau) ; p = nrow(tab_niveau) ; q = ncol(tab_niveau) ; m = min(p-1, q-1)
V_niveau = sqrt(chi_niveau$statistic/(n*m))
V_niveau

# Tableau final p-valeurs + V de Cramer
resultats_final = data.frame(
  Variable = c("sexe", "niveau"),
  p_valeur = round(c(chi_sexe$p.value, chi_niveau$p.value), 4),
  V_Cramer = round(c(V_sexe, V_niveau), 4)
)
print(resultats_final)

```