SAE

Modélisation des prix immobiliers dans l'agglomération niortaise

Taraud Adrien
Tiphaine Ducret

2025 - 2026

Régression sur des données réelles

Introduction

Dans le cadre de notre première année de BUT Science des Données, nous réalisons un projet de modélisation des prix immobiliers dans l'agglomération niortaise. Nous disposons de données réelles issues des transactions immobilières réalisées depuis 2021 dans les communes de la Communauté d'Agglomération du Niortais, portant sur deux types de biens : les maisons et les appartements.

Le jeu de données principal, composé de 5 107 transactions, contient des informations sur la localisation du bien, sa surface bâtie, sa surface terrain, son nombre de pièces ainsi que sa valeur foncière. Dans quelle mesure est-il possible de prédire le prix d'un bien immobilier niortais à partir de ses seules caractéristiques observables ? Pour répondre à cette question, nous présenterons dans un premier temps notre démarche de préparation et de segmentation des données, puis nous exposerons les modèles retenus pour chaque segment, avant d'analyser les performances obtenues. L'ensemble du travail de modélisation et de prédiction a été réalisé en R natif, sans librairie externe, en implémentant manuellement les formules statistiques vues en cours.

Nettoyage et préparation des données

Avant toute modélisation, les variables de surface, de terrain et de prix ont été converties en valeurs numériques, le format CSV2 les important initialement comme du texte sous R.

Pour aller plus loin dans notre analyse, nous avons cherché une variable externe capable d'expliquer les différences de prix entre communes. Notre choix s'est porté sur le revenu médian par commune, disponible dans le fichier INSEE Filosofi 2021 (pris sur le site internet de l'insee). L'idée est assez intuitive : dans une commune où les habitants gagnent bien leur vie, ils peuvent se permettre des logements plus grands et plus chers, ce qui fait naturellement monter les prix. En nous basant sur la médiane nationale de 22 530€, nous avons classé les communes en trois catégories : modeste, moyenne et riche. Cette démarche s'est avérée payante puisque les prix moyens passent de 142 000€ dans les communes modestes à 212 000€ dans les communes riches, soit une différence de 70 000€ qui justifie pleinement cette segmentation.

Segment	Nb biens	Prix moyen	Prix médian	Surface moyenne
Maison Niort	1897	181 278 €	165 000 €	92 m²
Maison hors Niort Riche	769	211 892 €	198 000 €	107 m²
Maison hors Niort Moyenne	990	170 480 €	165 000 €	108 m²
Maison hors Niort Modeste	382	142 655 €	130 000 €	102 m²
Maison Chauray	225	217 450 €	200 000 €	102 m²
Appart 1p	187	54 959 €	51 000 €	28 m²
Appart 2p	385	86 539 €	82 000 €	43 m²
Appart 3p+	497	127 625 €	115 000 €	71 m²

Enfin, pour chaque segment, les valeurs aberrantes ont été supprimées via une fonction de nettoyage. Plutôt que de filtrer sur le prix brut, nous avons calculé le prix au m² de chaque bien et supprimé les 10% les plus bas et les 10% les plus hauts. Cette approche est plus robuste car elle évite qu'un bien atypique comme un château ou une ruine ne vienne fausser la droite de régression.

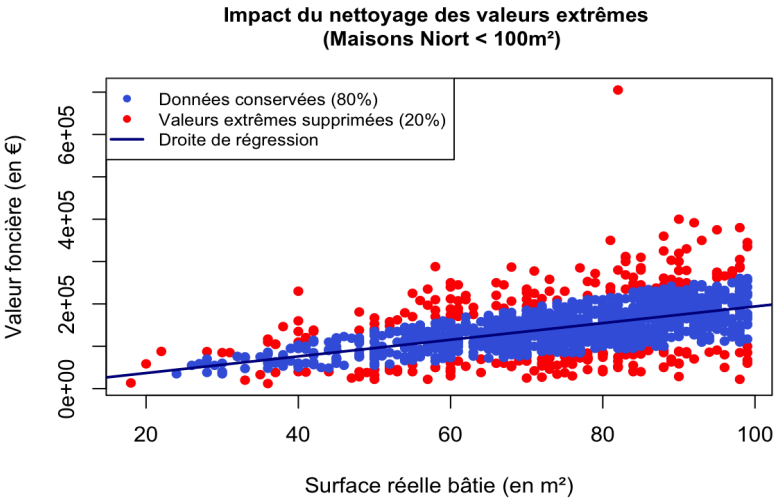

Sur ce graphique, les points rouges représentent les transactions atypiques (les 10 % les moins chères et les 10 % les plus chères au m²) qui ont été exclues par notre algorithme. Les points bleus représentent le cœur du marché conservé pour l'entraînement du modèle. Cette suppression permet à la droite de régression (en bleu foncé) de ne pas être attirée par les valeurs extrêmes et de s'ajuster fidèlement à la tendance réelle du marché.

Stratégie de modélisation et segments retenus

Le marché immobilier de l'agglomération niortaise étant hétérogène, nous avons segmenté les données en neuf sous-marchés avant d'appliquer nos modèles de régression. Pour les maisons, Niort (47 % des transactions) constitue un marché à part entière, divisé selon la surface bâtie (seuil de 100 m²). Chauray est isolée car son marché est particulièrement homogène (R2 = 0,787), tiré vers le haut par une population active stable liée au bassin d'emploi de la MAAF. Les maisons des autres communes sont ensuite classées selon leur revenu médian INSEE. Les appartements, quant à eux, sont segmentés par nombre de pièces, critère reflétant directement l'usage du bien.

Pour chaque segment, le choix du modèle a été dicté par le meilleur R2. Le modèle linéaire a été conservé pour les marchés standards. Le modèle logarithmique a été retenu pour les grandes maisons et les communes aisées : l'impact d'un mètre carré supplémentaire sur le prix diminue à mesure que le bien s'agrandit. Comme l'illustre la **Figure 3**, la courbe logarithmique (en vert) épouse bien mieux cette réalité que la droite linéaire classique (en rouge), qui surestime les grandes surfaces. Enfin, le modèle exponentiel s'impose pour les

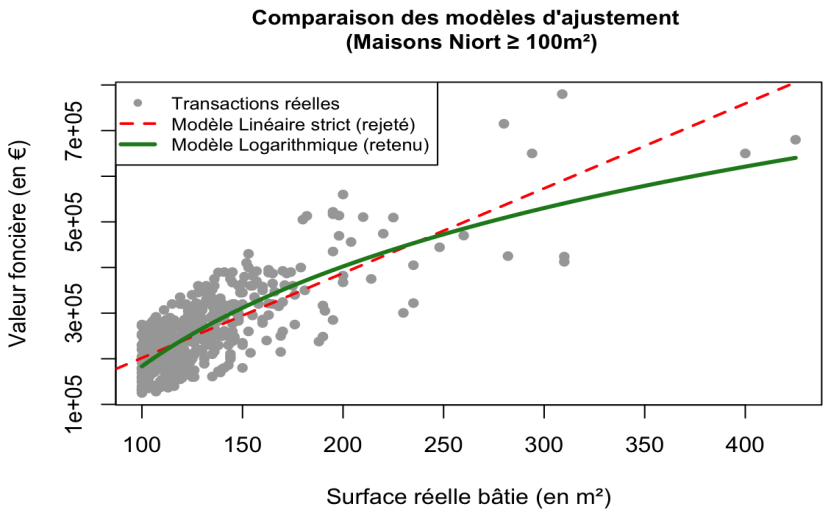

studios, dont le prix décolle très rapidement en raison de la forte tension sur les petites surfaces.

Le tableau suivant récapitule les modèles retenus et leurs performances :

Segment	Modèle	R^2	a	b
Maison Niort < 100m²	Linéaire	0.486	1 967.72	-2 524.08
Maison Niort ≥ 100m²	Logarithmique	0.614	315 698.10	-1 270 353
Maison Chauray	Linéaire	0.787	2 195.28	-7 467.55
Maison hors Niort/Chauray Riche	Logarithmique	0.662	199 106.90	-711 507.10
Maison hors Niort/Chauray Moyenne	Logarithmique	0.566	140 572.20	-476 396.80
Maison hors Niort/Chauray Modeste	Linéaire	0.590	1 299.53	9 477.68
Appartement 1 pièce	Exponentiel	0.444	0.0286	10.05
Appartement 2 pièces	Linéaire	0.440	1 497.95	20 692.63
Appartement 3 pièces+	Linéaire	0.523	1 823.35	-6 155.36

Résultats et performances

Évalué sur **`test.csv`**, notre modèle global atteint un R^2 de **0,512**. Expliquer plus de 50 % de la variance des prix avec seulement la surface, le type de bien et le revenu moyen est un résultat très satisfaisant, sachant que l'immobilier réel dépend de critères absents de nos données (état, exposition, DPE).

Ce score moyen cache d'ailleurs d'excellentes performances locales : sur un marché homogène comme Chauray, le R^2 grimpe à **0,787**, ce qui valide totalement notre stratégie de segmentation.

Enfin, pour garantir le rendu d'un fichier de prédiction complet et sans erreur, les rares biens de **`to_predict.csv`** comportant des données manquantes (comme le nombre de pièces) ont été évalués, par défaut, au prix moyen global du jeu d'entraînement.

Conclusion

Ce projet a été une réelle immersion dans le marché immobilier niortais. Au-delà des chiffres, nous avons cherché à comprendre sa logique en créant neuf segments basés sur la réalité du terrain et des données de l'INSEE. Cette stratégie a payé : notre modèle explique

plus de la moitié des variations de prix (R2 de 0,512 sur `test.csv`), un résultat solide pour des données réelles.

Évidemment, le prix d'un bien ne se résume pas qu'à sa surface. Des éléments invisibles dans nos fichiers, comme l'état général, le diagnostic énergétique ou un simple « coup de cœur », influencent aussi la valeur finale.

Travailler sur un jeu de données brut a été un exercice très formateur. De la segmentation stratégique à l'implémentation des formules sur R, ce projet nous a permis de passer de la théorie à la pratique, tout en développant un regard plus critique et plus juste sur l'analyse de données.